
基于产品订单的数据分析与需求预测的研究

摘要

近年来，经济复苏势头减弱，供应链持续紧张，通胀压力加大，影响和平发展的不稳定、不确定性因素依然存在等种种复杂多变的外部环境，让企业供应链面临较多难题。为了预测需求和协调活动，解决库存短缺和资金积压，制定采购和生产计划而减少业务波动，需求预测在产品订单数据分析中显得尤为重要。而想要完成本题产品订单的需求预测，则首先需要分析历史数据，推断出影响产品需求量的因素并分析其特性，以便后续进行需求量预测。

针对问题一，本文采用 **numpy**、**matplotlib**、**pandas**、**seaborn** 等方法将数据进行可视化。对于不同价格对需求量的影响，求出每类产品的平均需求量，绘制箱线图来排除数据中的异常值，用折线图将其进行可视化，考虑到产品质量和消费水平的因素，进而得出价格对需求量的影响。对于产品所在区域对需求量的影响，以及不同区域的产品需求量的特性，本文统计出每个地区产品的总需求量，并细化不同地区中不同品类产品的需求量，绘制直方图。对于不同销售方式（线上和线下）的产品需求量的特性，统计线上和线下两个方式的需求量总和，用直方图将其可视化进行对比分析。对于不同品类之间的产品需求量的不同点和共同点，根据产品编码、大类编码和小类编码，将产品分为八类大品类和十二类小品类，以时间为参考系，作折线图来讨论不同品类之间产品需求量的不同点和共同点。对于不同时间段产品需求量有何特性的问题，采用将每年的月份分为月初、月中、月末并统计相应的需求量，得知不同时间段产品需求量存在的差异性可能受到节假日、促销活动和季节的影响。对于节假日、促销活动和季节因素对产品需求量的影响，本文从时间节点的前一周、当周和后一周分析平均需求量，季节则相应进行分割。

针对问题二，本文采用 **Light GBM 预测模型(简称 LGBM)**；均值编码、特征工程、开窗数据拓展（**Windowing**）等算法构造并预测出订单需求量。根据题目要求，关于问题二的模型建立要基于问题一的数据分析，并预测 2019 年 1、2、3 月的产品订单需求量，且要把未来三月划分成天、周、月三个不同的时间粒度，察看哪一种时间粒度的需求量预测值更接近订单需求量的真实值。为了预测想要的结果，我们研究了多个回归模型、时间序列模型，最终决定建立 **LGBM 模型**，那么在建立预测模型前，还有众多准备工作——第一步，对问题一的数据进行深度分析并探索性研究，对日期进行不同方式的遍历及拆分从而构造不同时间粒度的索引列，分别是题设要求的日、周、月。第二步，获取预测全过程需要的数据列，删除对建立预测模型无用的索引列。第三步，完成历史数据的预处理后，检验目前已处理好的 **csv** 是否可以作为训练集，是则保存最终的数据表格。完成完成上述三项工作后可以开始建立我们需要的预测模型，为了不重复，在此简述建模的步骤——第一步，增加待预测的 2019 年三个月的数据，此过程采用了特征工程算法来构建需求量的趋势，最终计算出订单需求量的预测值。第二步，对预测数据进行测试并拟合，分析预测结果，检验预测模型是否符合标准。第三步，将日期划分成不同的时间粒度，对预测数据进行迭代处理，以此类推获取不同粒度下的订单需求量。最后本文对上述建模过程进行总结，基于产品订单需求量预测下，可以对本文所研究的该企业的产品给予相关的建议与销售策略。

关键词：需求量、LGBM、均值编码、特征工程、开窗数据拓展

目录

1、 绪论	4
1.1 赛题背景	4
2、 问题重述	4
2.1 问题一	4
2.2 问题二	4
3、 模型假设	5
4、 相关理论	5
4.1 Light GBM 预测算法	5
4.2 均值编码	5
4.3 特征工程	5
4.4 滑动窗口	6
4.5 开窗数据拓展	6
5、 数据分析处理及影响因素	6
5.1 数据描述	6
5.2 数据处理	6
5.2.1 重复值	6
5.2.2 缺失值	7
5.2.3 异常值	8
5.3 影响因素分析	8
5.3.1 内部因素	8
5.3.2 外部因素	9
6、 问题一	9
6.1 产品的不同价格对需求量的影响	9
6.1.1 异常值处理	9
6.1.2 数据分析	10
6.1.3 相关结论	12
6.2 产品所在区域对需求量的影响，以及不同区域的产品需求量特性	12
6.2.1 数据处理	12
6.2.2 相关结论	13

6.3 不同销售方式（线上和线下）的产品需求量的特性	14
6.3.1 数据处理	14
6.3.2 相关结论:	14
6.4 不同品类之间的产品需求量有何不同点和共同点	14
6.4.1 数据处理	15
6.4.2 相关结论	16
6.5 不同时间段产品需求量有何特性	17
6.5.1 数据处理	17
6.5.2 相关结论	17
6.6 节假日、促销对产品需求量的影响	17
6.6.1 数据分析	17
6.6.2 异常值分析	22
6.6.3 相关结论	23
6.7 季节因素对产品需求量的影响	24
6.7.1 数据处理	24
6.7.2 相关结论	24
7、 问题二	24
7.1 特征选择与数据处理	25
7.1.1 特征选择	25
7.1.2 数据处理	25
7.2 模型建立与误差分析	25
7.2.1 模型建立	25
7.3 预测	26
7.3.1 建模过程一	26
7.3.2 建模过程二	26
7.3.3 拟合偏差分析	26
7.3.4 检验模型	30
7.4 不同时间粒度的预测情况	30
7.5 特征值的重要程度	32
7.6 预测新产品的需求量	33
8、 总结	35
9、 参考文献	36

1、 绪论

1.1 赛题背景

近年来，国内外形势仍存在很多不稳定性、不确定性因素，形势更趋复杂严峻。从外部形势看，全球通胀、供应链短缺、国际局势等问题短期内难以完全解决，经济复苏和增长仍面临不确定性。从内部形势看，我国经济发展面临需求收缩、供给冲击、预期转弱等压力。在这些众多因素的影响下，企业供应链面临着较多难题。一是供应链的复杂性和风险不可预测性，二是供应链效率低下，响应速度滞后，三是无法有效地评估和衡量供应链绩效，四是无法确定供应链改善的关键环节和优先顺序，五是很难培养高端供应链管理人才。而要想解决这些问题，就需要建立预测，于是，需求预测的重要性便不言而喻。^[1]

需求预测是对未来市场需求的预估，通过预测未来某一时段内客户对于产品的需求，企业可以提前购买原材料、安排生产活动，以应对客户的需求变化。其中预测又分为两大类，定性预测和定量预测。

定性预测带有很强烈的主观判断，是依靠经验、直觉和有根据的推测做出的预测，通常用于缺少历史数据的产品；或是企业中长期的战略规划；或是作为定量预测的补充手段，受主观判断影响，更容易出现偏差。定量预测则是根据以往的历史数据，运用各种数学公式对市场未来发展趋势作出定量的计算，求得预测结果。这种方法更加客观且准确，适用于企业对产品订单的数据分析。常用的定量预测方法主要有时间序列分析法和因果分析法。通过使用企业内部数据和利用事物发展变化的因果关系进行预测。要想做出精确的市场预测，企业往往需要将定量分析和定性分析相结合，通过收集以往历史数据进行分析进而对未来做出判断，并且持续改进、优化，提高预测准确性，达到解决库存和资金积压、降低库存成本的问题。^[2]

2、 问题重述

2.1 问题一

对产品数据信息进行深入分析，解决以下问题：

- (1)产品的不同价格对需求量的影响；
- (2)产品所在区域对需求量的影响，以及不同区域的产品需求量有何特性；
- (3)不同销售方式（线上和线下）的产品需求量的特性；
- (4)不同品类之间的产品需求量有何不同点和共同点；
- (5)不同时间段（例如月头、月中、月末等）产品需求量有何特性；
- (6)节假日对产品需求量的影响；
- (7)促销对产品需求量的影响；
- (8)季节因素对产品需求量的影响。

2.2 问题二

基于上述分析，建立数学模型，对附件预测数据（predict_sku1.csv）中给出的产品，预测未来3月（即2019年1月、2月、3月）的月需求量。分别按天、周、月的时间粒度进行预测，分析不同的预测粒度对预测精度会产生什么样的影响。

3、 模型假设

- (1)假设所有表格数据信息真实可靠
- (2)假设除节假日、促销活动日等时间因素、产品品类因素和消费者消费水平因素外，其他如社会事件因素等对产品需求量的影响很小
- (3)假设未来的时间、消费条件与历史数据一样

4、 相关理论

4.1 Light GBM 预测算法

同XGBoost类似，LightGBM是在GBDT算法框架下的一种改进实现，是一种基于决策树算法的快速、分布式、高性能的GBDT框架，主要解决的痛点是面对高维度大数据时提高GBDT框架算法的效率和可扩展性。Light主要体现在三个方面，即更少的样本、更少的特征、更少的内存，分别通过单边梯度采样（Gradient-based One-Side Sampling）、互斥特征合并（Exclusive Feature Bundling）、直方图算法（Histogram）三项技术实现。另外，在工程上面，LGBM还在并行计算方面做了诸多的优化，支持特征并行和数据并行，并针对各自的并行方式做了优化，减少通信量。

4.2 均值编码

均值编码 (Mean Encoding)，也称为 Target Encoding，是一种用于处理分类特征的技术，它将每个分类变量替换为其相应目标变量的均值。在均值编码中，对于每个类别变量的值，我们计算该类别的目标变量的平均值，然后将该平均值作为该类别的编码值。

均值编码的目的是将分类变量转换为连续变量，以便于机器学习算法的使用。它可以有效地捕获分类变量与目标变量之间的关系，因为它使用了目标变量的信息来编码分类变量。

4.3 特征工程

特征工程是利用数据领域的相关知识来创建能够使机器学习算法达到最佳性能的特征的过程。特征工程又包含了 Feature Selection（特征选择）、Feature Extraction（特征提取）和 Feature construction（特征构造）等子问题。在实际项目中，可能会有大量的特征可使用，有的特征携带的信息丰富，有的特征携带的信息有重叠，有的特征则属于无关特征，如果所有特征不经筛选地全部作为训练

特征，经常会出现维度灾难问题，甚至会降低模型的准确性。因此，需要进行特征筛选，排除无效/冗余的特征，把有用的特征挑选出来作为模型的训练数据。

4.4 滑动窗口

滑动窗口统计（Sliding Window）是一种常见的算法技巧，主要用于处理数据流或者数组中的连续区间问题。它的核心思想是维护一个固定大小的窗口，并且通过移动窗口来计算满足特定条件的区间。

滑动窗口统计算法的基本步骤如下：

初始化窗口：定义一个窗口的左边界和右边界，并根据问题要求选择合适的窗口大小。

移动窗口：向右移动窗口，更新窗口的左边界和右边界。

计算窗口内的结果：根据问题的要求，计算当前窗口内的结果。

更新答案：将计算出的结果与当前的最优解进行比较，并更新答案。

继续移动窗口，重复步骤 2-4，直到遍历完整个数据流或者数组。

4.5 开窗数据拓展

开窗数据拓展（Windowing）是一种数据处理技术，主要用于在流数据或者连续事件序列上执行各种计算操作。开窗技术通过将数据流分割成一系列固定大小的窗口，并在每个窗口上执行计算操作，从而对数据流进行分析和处理。

开窗数据拓展的基本思想是，将连续的数据流划分为多个窗口，并在每个窗口内进行数据分析和计算操作。开窗操作通常需要指定窗口的大小、滑动步长和聚合函数。常见的聚合函数包括求和、计数、平均值、最大值、最小值等等。通过不断滑动窗口，可以不断地对数据流进行分析和计算，从而得到更加准确的数据处理结果。

5、 数据分析处理及影响因素

5.1 数据描述

数据表格(order_train1.csv)为 2015 年 9 月 1 日至 2018 年 12 月 20 日的产品订单信息，可以读出每个产品的订单日期、销售区域编码、产品编码、产品大类编码和细类编码、销售渠道(线上、线下)、产品价格和订单需求量，共计 543815 行产品信息。由于不同消费者的经济水平存在差异，可能会有极端产品价格以及对应的需求量的问题。

数据表格(predict_sku1.csv)提供了需要预测产品的销售区域编码、产品编码、产品品类和产品细品类，通过第一问的分析，会对第二问进行预测。

5.2 数据处理

5.2.1 重复值

据进行读取，使用 describe 进行数据探索分析(如图 1)

	order_date	sales_region_code	item_code	first_cate_code	second_cate_code	sales_chan_name	item_price	ord_qty
0	2015/9/1	104	22069	307	403	offline	1114.0	19
1	2015/9/1	104	20028	301	405	offline	1012.0	12
2	2015/9/2	104	21183	307	403	online	428.0	109
3	2015/9/2	104	20448	308	404	online	962.0	3
4	2015/9/2	104	21565	307	403	offline	1400.0	3
...	...	...	...	...	...	...	...	...
597689	2018/12/20	102	20994	302	408	offline	843.0	59
597690	2018/12/20	102	21875	302	408	offline	762.0	502
597691	2018/12/20	102	20215	302	408	offline	2013.0	106
597692	2018/12/20	102	20195	302	408	offline	2120.0	187
597693	2018/12/20	102	20321	302	408	offline	1244.0	205

597694 rows × 8 columns

图 1

去重有：

	order_date	sales_region_code	item_code	first_cate_code	second_cate_code	sales_chan_name	item_price	ord_qty
0	2015/9/1	104	22069	307	403	offline	1114.0	19
1	2015/9/1	104	20028	301	405	offline	1012.0	12
2	2015/9/2	104	21183	307	403	online	428.0	109
3	2015/9/2	104	20448	308	404	online	962.0	3
4	2015/9/2	104	21565	307	403	offline	1400.0	3
...	...	...	...	...	...	...	...	...
597689	2018/12/20	102	20994	302	408	offline	843.0	59
597690	2018/12/20	102	21875	302	408	offline	762.0	502
597691	2018/12/20	102	20215	302	408	offline	2013.0	106
597692	2018/12/20	102	20195	302	408	offline	2120.0	187
597693	2018/12/20	102	20321	302	408	offline	1244.0	205

597382 rows × 8 columns

图 2

5.2.2 缺失值

将去重之后的数据进行缺失值检验，发现没有缺失值

	特征	缺失数量	缺失百分比
0	order_date	0	0.0
1	sales_region_code	0	0.0
2	item_code	0	0.0
3	first_cate_code	0	0.0
4	second_cate_code	0	0.0
5	sales_chan_name	0	0.0
6	item_price	0	0.0
7	ord_qty	0	0.0

图 1

5.2.3 异常值

将产品价格和需求量化进行可视化：(如图 4)




图 2

产品价格存在异常过高情况，作箱线图进行分析：(如图 5)

绘制箱线图的上下范围，上限为上四分位数，下限为下四分位数。大于上四分位数 1.5 倍四分位数差的值，或者小于下四分位数 1.5 倍四分位数差的值，划为异常值。异常值又分为极端异常值和较为温和的异常值。极端异常值，即超出四分位数差 3 倍距离的异常值；较为温和的异常值，即处于 1.5 倍-3 倍四分位数差之间的异常值。^[3]

通过绘制箱线图，可以判断产品价格的异常值，具体在问题 6.1 呈现。

5.3 影响因素分析

5.3.1 内部因素

从产品本身来看，产品需求量的大小与产品的价格、品类等有关。如产品价格过低，成本会过低，导致产品质量会无法保证；产品价格过高，无法满足很多消费者的消费水平。又如产品品类也会影响消费者的购买心理。




图 5

5.3.2 外部因素

从外部环境看，不同时间段也会对产品需求量产生影响。例如节假日时期人们会休闲娱乐，大概率会出现消费倾向；又如电商平台的发展，很多电商会定期举办促销优惠活动，也会刺激消费。

6、 问题一

6.1 产品的不同价格对需求量的影响

将全部数据读取出来，提取出产品价格和需求量两列，求出平均需求量，绘制折线图，发现产品价格集中分布在(0,10000)内，且平均需求量波动幅度较大，推测可能出现异常值。为了准确讨论不同价格对需求量的影响，我们选择将数据集中分布的区间扩大细化。

6.1.1 异常值处理

通过绘制箱线图进行异常值处理工作。将全部数据进行可视化，发现数据异常密集，由此判断存在异常值，需要进行处理。对此我们将产品价格进行细化。将(0,2000]进行可视化，发现数据在正常范围内(如图 6)，同理操作(2000,3500](如图 7)，(3500,10000](如图 8)，以此类推，最后发现价格在 10000 以后箱线图严重压缩(如图 9)，由此可以判断 10000 以后的数据为异常值。




图 3




图 7
部分数据的价格分布




图 8
部分数据的价格分布




图 9




6.1.2 数据分析

以上的异常值处理，现集中讨论产品价格 $\in (0, 10000]$ 之间的平均需求量和产品价格的关系。将该区间的数据进行数据探索处理(如图 10)，将产品价格分为低价格 $(0, 598]$ ，中价格 $(598, 883]$ ，较高价格 $(883, 1290]$ 和高价格 $(1290, 10000]$ (如图 11 含四张图)

```
item_price
25%      598.0
50%      883.0
75%     1290.0
Name: item_price, dtype: float64

count      597334.000000
mean       1062.472912
std        767.127553
min         1.000000
25%        598.000000
50%        883.000000
75%       1290.000000
max       9991.000000
```

图 4






图 11

6.1.3 相关结论

- (1) 低价格区间绝大多数的平均需求量极低，极少数产品价格的平均需求量较为特殊，呈现平均需求量极高的情况。
- (2) 中价格区间整体呈现与平均需求量关系较为密切的情况，即绝大多数的价格对应的平均需求量较高，其中少数价格对应的平均需求量极高，除此之外仅有少数的价格与平均需求量之间的联系较弱而呈现平均需求量较少的情况。
- (3) 较高价格区间与中价位区间，在图示上有相似的特征，即绝大多数的价格与平均需求量之间的联系较为紧密，但较中价位的联系有所减弱，较高价格区间内少数价格对应的平均需求量在该价位占比极高，但在平均需求量的数目上较中价位减少许多。
- (4) 同理，高价位也有相似的类推结论，即价格与平均需求量的之间的联系进一步减弱，且平均需求量的数目也进一步减少。

通过数据分析，可以得知，中价位产品更受消费者的青睐，原因可能是低价格产品的质量难以保证以及高价位产品对应的消费水平对于消费者来说难以达到。

6.2 产品所在区域对需求量的影响，以及不同区域的产品需求量特性

6.2.1 数据处理

首先，统计不同区域(101,102,103,104,105)所有产品需求量的总合，用直方图进行可视化(如图 12)。其次将每个地区的产品进行细化，统计出八类产品在五个地区的需求量情况，同样可视化呈现(如图 13)。




图 12




图 13

6.2.2 相关结论

(1)104 地区的产品需求总量最少，且与其他四个地区的需求总量差距极大；105 地区的产品需求总量最多。可能由于销售区域的地理位置以及经济水平等因素的影响，导致不同区域产品的需求量存在较高或较低的差异。

(2)分析不同区域不同品类产品的需求量的同异性，可以看出每一地区对 304 号、301 号产品的需求量都很低，而对 306 号产品，除在 104 地区没有销售外，其他地区的需求量都很高

(3)从不同点来看，除去需求量普遍较高的 306 类产品之外，101 地区对 305 类产品的需求量更高，102 地区对 302、305、308 类产品的需求量更高，103 地区对 302 类产品的需求量更高，104 地区对 307、308 类产品的需求量更高，105 地区对 302、305 类产品的需求量更高。

(4)总之，除反常的 104 地区外，不同区域的产品需求量总体情况相似，其中有个别产品的需求量在不同区域会有不同的情况。

6.3 不同销售方式（线上和线下）的产品需求量的特性

6.3.1 数据处理

将数据导入，将线上与线下分成两组，计算出它们的基本统计量，了解分布情况和差异性(如图 14)。再求出线上和线下两个方式总需求量之和，做出对应的直方图来进行对比分析。(如图 15)

线上:		线下:	
count	158222.000000	count	439112.000000
mean	112.529876	mean	84.195629
std	234.369200	std	185.337565
min	1.000000	min	1.000000
25%	12.000000	25%	9.000000
50%	37.000000	50%	26.000000
75%	108.000000	75%	91.000000
max	16308.000000	max	16301.000000
Name: ord_qty, dtype: float64		Name: ord_qty, dtype: float64	

图 14




图 15

6.3.2 相关结论:

线下销售方式所对应的产品需求量和销售总额均远高于线下，证明线下销售渠道对于产品需求量的贡献较大。

线上销售渠道与传统实体店销售渠道相比，两者的最大区别是市场透明度不同。线上销售比线下销售的市场透明度高，线上常常提供了丰富的商品价格信息和产品信息，这两种信息的透明化，对消费需求产生此消彼长的影响。在互联网这种高透明的销售渠道中，消费者既容易知道替代品的价格信息，也容易知道同类产品的价格信息，于是会在价格信息的比较当中，产生购买品质相同而价格更低的产品，放弃购买品质相同而价格更高产品的欲望。由此可见，线上由于价格信息透明，导致消费需求减少。^[4]

6.4 不同品类之间的产品需求量有何不同点和共同点

6.4.1 数据处理




图 16

表 1

产品分类	
大类编码	小类编码
301	405
302	408
303	401
	406
	410
	411
304	409
305	412
306	402
	407
307	403
308	404

不同产品有不同的编码(如图 16)，按照产品品类(first_cate_code、second_cate_code)进行统计，可以分为八大类产品，而每一大类又对应多个小类(共计 12 小类)

为了更好地分析不同品类产品需求量之间的同异性，我们选择从时间的角度来观测不同产品的需求量。将 2015 年 9 月到 2018 年 12 月按月份分为 40 组，分别统计每大类产品每月的总需求量，以及每小类产品每年的总需求量，用折线图将其可视化(如图 17、18)，得到不同品类与需求量的关系。




图 17

6.4.2 相关结论

相同点:

- (1) 每一大品类需求量按月份走势基本相同，每类产品需求量最高对应的月份(如 10、11 月份)和需求量最低对应的月份(如 1 月份)也基本一致。
- (2) 每年中小品类产品的需求量的走势也基本相同。

不同点:

- (1) 无论在哪个月，大类产品中 306 的需求量最高，304 的需求量最低
- (2) 从每年来看，小类产品中 407 的需求量最高，而对 406、411 类产品的需求量最低(其中 406 在 2015 年 9 月到 2015 年 12 月间无销售，411 在 2015 年 9 月到 2017 年 9 月间无销售)。

可能受到节假日、促销活动和季节等时间因素以及产品本身类型的影响，不同品类的产品需求量才会有如此差异。




图 18

6.5 不同时间段产品需求量有何特性

6.5.1 数据处理

按月统计 2015 年到 2018 年的产品需求量，并将每个月分为月初、月中、月末，分别统计对应的需求量，用折线图将其可视化(如图 19)。

6.5.2 相关结论

每月每旬的产品需求量走势基本相似，存在特定的时间段或时间点的产品需求量异常高或异常低的情况，如在每年的 10、11、12 月份的产品需求量相较于其他月份更高。

可能是受到节假日以及促销活动等外部因素的影响，从而刺激消费者的消费心理。由此我们接下来详细讨论节假日、促销活动以及季节因素对需求量的影响。




图 19

6.6 节假日、促销对产品需求量的影响

6.6.1 数据分析

节假日以及促销日通常会开展折扣活动进而影响产品的需求量情况，现统计 2015 年至 2018 年的节假日以及促销活动日期。

表 5-1

元旦	春节	清明节	劳动节	端午节	中秋节	国庆节
----	----	-----	-----	-----	-----	-----

2015						9.27	10.1
2016	1.1	2.8	4.4	5.1	6.9	9.15	10.1
2017	1.1	1.28	4.4	5.1	5.30	10.4	10.1
2018	1.1	2.16	4.5	5.1	6.18	9.24	10.1

表 5-2

	情人节	女神节	母亲节	父亲节	6.18	双十一	双十二
2015						11.11	12.12
2016	2.14	3.8	5.8	6.19	6.18	11.11	12.12
2017	2.14	3.8	5.14	6.18	6.18	11.11	12.12
2018	2.14	3.8	5.13	6.17	6.18	11.11	12.12

首先将数据按日期进行统计，提取出每天的需求量；以节假日和促销日为时间节点，分别检索每个节点的前一周、当周和后一周的需求量。

在统计的过程中，出现有时间数据的缺失现象导致样本容量不一致，因此以需求量总和来作为观测标准不具有较好的参考价值，我们选择求平均值来减小误差。

用直方图进行可视化：(图 20、21、22、23 为节假日，图 24、25、26、27 为促销日)




图 20




图 21




图 22




图 23




图 24




图 25




图 26




图 27

6.6.2 异常值分析

从柱状图中可以看到，2016 年的春节、2017 年的春节、2018 年的情人节出现了需求量极高或为零的情况，我们将其提出进行讨论。

2016 年春节(2.8)




图 28

由于春节当周的数据缺失，因此在对应的直方图上呈现出异常的零值。

2017 年春节(1.28)




图 29

春节当周只有 2.3 当天存在数据且平均需求量极高，所以在上述直方图中会出现当周数值极高的情况。

2016 年情人节(2.14)




图 30

情人节前一周存在数据缺失，同理 2016 年春节。

2018 年情人节(2.14)




图 31

同理 2016 年春节、2016 年情人节。

6.6.3 相关结论

从上述柱状图可以看出，节假日和促销日对产品的需求量存在影响，普遍趋势为：在特定时间点(节假日、促销日)的前一周与当周的产品需求量高于后一周，节假日与促销日会刺激消费者的购买冲动。

商品的销售量主要受到宏观经济、价格、消费者偏好和消费环境等因素的影响。商家之所以选择促销商品无外乎是想增加销量达到某种目的，与促销前产品

的市场销量相比，促销时产品销量上升，增加的原因是由于促销对消费者产生吸引力。在促销活动结束后的一段时期内，称为有货消耗期，消费者因消耗在促销期间积累的存货而没有实施新的购买，从而商品销量在刚结束的时候略有下降，但这段时间过后，商品销量比促销前上升，说明促销取得了良好的效果，使产品的销售增加。^[5]

6.7 季节因素对产品需求量的影响

6.7.1 数据处理

将数据日期与需求量统计出来，将 2015 年到 2018 年每年的四季划分出来，同理上题的缺失值处理，我们采用平均需求量进行分析，用直方图进行可视化。(如图 32)




图 32

6.7.2 相关结论

季节因素对产品需求量有较大影响，该产品需求量变动具有较明显的季节性特征：

(1)除 2018 年以外，每年的秋冬季产品需求量高于春夏季，每年的普遍趋势为秋季需求量高于冬季，春季需求量高于夏季。有一定的规律性和周期性；每年重复出现，具有重复性；波动轨迹具有相似性。^[x]

(2)与其他年份不同，2018 年春季平均需求量比其他季节更高。

2018 年是中国经济自 1990 年以来，对外公布的最低经济增速。自 2018 年一季度以来，中国 GDP 的季度增速已经连续第三次下滑，一、二、三季度国内生产总值（GDP）同比分别增长 6.8%、6.7%和 6.5%。可能是经济环境的影响(全民去杠杆化、社保改革、中美贸易战三座大山的影响)大于季节因素的影响，因此在 2018 年产品的需求量呈现反常情况。^[6]

7、 问题二

7.1 特征选择与数据处理

7.1.1 特征选择

本题需要预测 2019 年 1、2、3 月的需求量，依次按天、周、月的时间粒度进行预测，分析对比不同粒度预测对预测精度造成的影响。因此需要对需求量、天、周、月时间进行深度探索分析。

7.1.2 数据处理

- (1) 提取出每个地区的数据,发现 104 地区仅有 2015 年 9 月到 2016 年 12 月数据,又因为最终预测表格中没有涉及 104 地区的产品,所以我们选择剔除 104 地区,再处理每个地区对应的每日需求量。
- (2) 分析处理每个地区的数据,具体操作如下:
 - a) 对已划分好的价格区间进行分箱操作;
 - b) 对月份(月初、月中、月末)、节假日、季节以及销售方式(线上、线下)进行编码转换;
 - c) 对日期列进行构造(构造出星期、工作日、周末,并进行编码处理);
 - d) 剔除无用列(如年、产品价格等),后续将预测出的 19 年 1 月份数据拼接其后。
- (3) 根据第一大题的第一小问,首先将价格粗分为四个区间:低价格、中价格、较高价格、高价格,绘制出四个地区在不同价格区间对应的订单需求量的折线图(如图 33)




图 33

再将价格进行细分,便于探究更细致的价格区间对预测模型的影响(如图)。

7.2 模型建立与误差分析

7.2.1 模型建立

针对本题建立 LGBM 模型,划分不同的时间粒度对需求量进行预测。第一步先保存删除掉无用列后的 csv,建立模型的过程中,需要引入特征工程算法、




图 34

滑动窗口统计算法等诸多算法去构建足够的数据作为训练集以预测未来的需求量。

7.3 预测

7.3.1 建模过程一

- 1、读取(除 104 地区外)的数据表格，给每一份订单构造名为“zuhe”的组合列（该组合列由销售区域编码、大类编码、细类编码、产品编码组成）；
- 2、需要计算出有多少种产品，并将其需求量赋 0；
- 3、由于增加了待预测的 2019 年 1、2、3 月的数据，故需要构造促销日期列、星期列、季节列等原表格的所有标签列；
- 4、合并后用 info 函数对表格中每一列变量进行探索性分析；
- 5、在此需注意将 temp_df 转换为 df 格式方便后续读取。

7.3.2 建模过程二

- 1、产品需求量的构造，我们引入机器学习中的特征工程，而滞后特征是将时间序列预测问题转化为监督学习问的经典方法之一。
- 2、我们需要对产品需求量引入滞后，因此采用 shift 函数最大延迟天数（本文自定 60 天）。此项操作构造了 need_lag_1-60 的均值编码表示需求量的概率，需要对每一列的编码求均值，条件是拼接处理后 csv 中特征列的每一个值。
- 3、为了计算出预测月（1 月）的需求量，需要采用滑动窗口统计算法，计算已有具体需求量表里的周销售的滚动平均数，引入更多的特征如最小（大）值、区间平均值等，确保后期建立需求量趋势时，更大程度拟合最终真实需求量。
- 4、在滑动窗口时，窗口的大小不会因为窗口随时间的移动而发生变化，因此，构建需求量特征只需要考虑最近的值，应计算需求量扩大平均值，同时也可以计算更多特征，有利于拟合需求量的架构。
- 5、代码实现过程中，需要创建另外一个特征——需求量趋势构建，先判断每日需求量是否大于持续时间的平均值，是则赋为正值，并可以添加许多趋势特征。
- 6、在创建好所有需要的新特征后，保存此数据作为训练集并建立 LGBM。需要注意的是，因为最大延迟天数为 60 天，引入了许多 NULL 值，因此要删除掉前 60 天的数据。

7.3.3 拟合偏差分析

建立每个地区所有产品的模型，训练并验证已有的训练集和测试集，以下是各个地区关于训练集和测试集误差分析的函数图像，观察其函数损失情况。选择合适的地区为例建立模型。纵坐标分别表示每个地区的均方根误差（简称 RMSE）、平均绝对百分比误差（简称 MAPE），二者为回归预测模型中常见的评估指标，计算二者的公式在此不一一详述。




图 35




图 37




图 36




图 39




图 38




图 41




图 40

图 42

观察以上八个图，可以得出结论：不同地区拟合效果不一，关于 MAPE 接近的地区有 102、105，关于 RMSE 有重叠部分的是 105、103 地区。综合来看，编号为 105 的地区偏差最小，拟合效果最佳。

7.3.4 检验模型

为了检验以上所建立的回归模型，我们挑选出 105 区域模型对其进行验证，得出以下参数结果：

(`colsample_bytree=0.8`, `learning_rate=0.3`, `max_depth=8`, `min_child_weight=300`, `n_estimators=1000`, `num_leaves=50`, `subsample=0.8`) 括号内为 `LGBMRegressor` 模型的参数，`colsample_bytree=0.8` 表示在构建每棵树时，列采样率为 0.8，即每次随机选择 80% 的特征进行建树；`learning_rate=0.3` 表示学习率为 0.3，即每次更新树的时候乘以 0.3；`max_depth=8` 表示每棵树的深度为 8 层；`min_child_weight=300` 表示每个叶子节点上的最小权重为 300，如果一个叶子节点的权重小于该值，则不再进行分裂；`n_estimators=1000` 表示总共构建 1000 棵树；`num_leaves=50` 表示每棵树的叶子节点数量为 50；`subsample=0.8` 表示在构建每棵树时，行采样率为 0.8，即每次随机选择 80% 的样本进行建树。以此增强模型建立的可信度与说服力。

将日遍历一列划分为三个区间，分别是 (1, 1176)、(1176, 1208) 和大于 1208 的区间段，获取后两个区间对应的总需求量（再次须注意换成 `dataframe` 格式）

7.4 不同时间粒度的预测情况

建立好模型后，测试原有数据以及特征构造并计算出来的数据，获得关于日遍历所得出的需求量的真实值与预测值的折线图：




图 43

依据此图进行可视化分析，本文可以得出结论：在编码为 105 地区，关于产品需求量的日预测，真实值与预测值重叠度高，预测值与真实值的拟合效果良好。

接下来，本文将讨论周预测以及月预测的数据可视化分析，再将对应数据的折线图进行一一比对，观察在划分时间粒度的基础上，哪一种时间粒度的拟合效果最

佳，也就是预测值最接近真实值。

关于周预测（训练集数据的日期跨度为 2015-09-01 至 2019-01-31）的折线图：




图 44

关于月预测的折线图（训练集数据的日期跨度为 2015-09-01 至 2019-01-31）：




图 45

A.关于日预测：读取 csv 中的 D 列（前面构造出来的日遍历），将 2019 年 1、2、3 月份划分为天数共计 90 天，因题目不对 2018-12-20 到 2018-12-31 这部分作预测需求，我们在构造 2018-12-20 到 2018-12-31 的日数据的基础上删去其具体数据以简化可视化的结果，但保留其数据对 2019 年未来三月的影响。通过图 43 可以看到，其预测结果和原训练营的拟合结果基本重合，说明其结果是合理的，在此模型下预测的数据是具备参考的价值的。下面考察不同的粒度预测对拟合结果产生的影响，并由此选出最佳的预测粒度作为最终的预测结果。

B.关于周预测，获取上一步处理并保存好的数据作为训练集，对其中的日期列进行周遍历，记作 W 列，这里我们只选取 2019 年 1 月的预测进行粒度预测的对比，选取 2019 年 2 月和 3 月作预测对比相同，在此不赘述。通过图 44，我们可以看到，周粒度预测下，预测的拟合情况较日粒度预测有所减弱。根据代码和遍历的

逻辑，我们可以推断月粒度预测的拟合情况会更弱，下面验证这点猜想。

C.关于月预测：同理周预测的准备工作，我们对训练集进行月遍历，记作 M 列。再进行和周粒度一样的预测思路，即运用特征工程算法，以此作出 2019 年 1 月的月粒度预测。可以由图 45 看到，其拟合程度较周粒度预测更弱。

综上：对比上述不同时间粒度的折线图，观察得出，在粒度预测的划分中，日粒度预测的拟合效果最佳，周粒度预测次之，月粒度预测最差。由此可得出结论：建立 LGBM 回归模型时，训练集时间粒度划分越细，得出的关于需求量的预测值越接近真实值。由实际生活相关经验也可得出类似的思想。

7.5 特征值的重要程度

在数据集中选择除了"订单需求量"之外的所有特征，遍历所有文件，下载前面已经构建好的所有文件，计算每个特征值的重要程度，将特征的重要性存储在一个数据框中(如图)：




图 46

上图对每个模型计算特征重要性，并将结果保存在一个数据框 (feature_importance_df) 中。通过调用 display_importances 函数来显示特征的重要性。这个函数将按平均特征重要性的降序排列，并将前 20 个特征的重要性显示在水平条形图上。目的是帮助了解哪些特征对于预测订单需求量最为重要。

7.6 预测新产品的需求量

关于赛题所给数据——predict_skul.csv，其中除了不包括 104 地区的销售情况，处理表格时还发现多出了新产品，由于新产品没有历史数据，我们采取以下步骤获取新产品的需求量。

- 1、读取之前构造好的 19 年 1 月份的数据（保存在 result 里）；
- 2、将预测的各产品的 1 月需求量制作透视表，计算各个产品 1 月总需求量；

-
- 3、求每种产品在各个地区各编码的预测需求量的均值，用来表示新产品的预测值；
 - 4、保存以上数据，整合进赛题所给的 `predict_sku1.csv`，一一匹配汇总；
 - 5、在此检查合并的新表格有无问题。若无问题，将预测表格给出的新产品以同类型的产品的均值进行填充。再次检查，无误后保存预测数据。

以上是对于 2019 年 1、2、3 月订单需求量的预测的全过程，需要说明的是，关于天预测，本文预测到了 2019 年 1 月 1 日-2019 年 3 月 31 日共计 90 天的数据；关于周预测，本文预测到了 2019 年 1 月份的数据；关于月预测，本文预测了 2019 年 1 月份的数据，那么对于 2 月份，我们应当采用 1 月份为训练集，继续上述操作，得出 2 月份的预测数据，3 月份同理，因原理与操作类似，为避免繁琐，本文不一一列举。

8、 总结

(1)本文主要讨论了产品的价格、销售区域、销售方式、产品品类、时间段、节假日、促销日以及季节因素对产品需求量的影响及特性，首先对数据进行分析，对数据进行去重、缺失值检验和处理，以及使用箱线图排除数据中的异常值，然后主要采用 `numpy`、`matplotlib`、`pandas`、`seaborn` 等方法将数据进行可视化，做出了折线图、直方图等示意图帮助我们更好地理清各因素之间的关系。针对第二大问，通过建模之前的准备，我们发现 `LGBM` 更加适合本次的时间预测，于是结合第一大问各因素对产品需求量的影响，结合 `LGBM` 模型、及特征工程、滞后特征以及滑动窗口等方法进行建模和预测。

(2)对该企业的产品来说，其需求量不仅受内部因素如价格、产品品类等的影响，而且受外部因素如线上或线下的销售方式、节假日和促销活动等的影响。这些因素或多或少关联到消费者的经济水平、消费心理，从而出现不同需求量的情况。

(3)通过此次的数据分析，我们得知，企业可以通过详细分析历史数据得出相关联系与结论来预测未来的销售情况，通过使用恰当的手段、优秀的算法进行分析可大大提高预测的准确度。不断完善销售渠道的各个流程，丰富并创新新型产品，从而让企业在诡谲多变的经济外部环境下脚踏实地、稳中求进。

9、参考文献

- [1] 2022 年经济环境和形势的总体研判. 经济形势报告网. <http://www.china-cer.com.cn/>.2022-05-05
- [2] 需求预测的基本方法. 知乎网. 作者: Merry
- [3] 箱线图的理解. CSDN. 作者: Takoony
- [4] 刘晓明. 线上和线下销售并存的消费需求变化机理分析. 经济研究导刊, 1673-291X (2015) 11-0121-02
- [5] 李林峰. 简述商品促销对企业销售量的影响. 豆丁网. 2020-12-01
- [6] 2018, 中国经济遭遇三座大山. 知乎网. 作者: 妙盈科技 MioTech. 2019-02-18
- [7] 《XGBoost、LightGBM 的原理、公式推导、Python 实现和应用》. 作者: 大火山
- [8] 回归评价指标: MSE、RMSE、MAE、MAPE、R2 公式理解及代码实现. CSDN 网. 作者: 就是求关注